



UNIVERZITET U NOVOM SADU
PRIRODNO MATEMATIČKI FAKULTET
DEPARTMAN ZA
MATEMATIKU I INFORMATIKU



MASTER RAD

Intrinzična dimenzionalnost i njen uticaj na neke aspekte mašinskog učenja

Mentor

dr Miloš Radovanović

Student

Nikola Radojčić 79m/22

1. oktobar 2024.

Predgovor

Mnogi problemi za tehnike analize podataka, mašinskog učenja i sličnih oblasti, nastaju pri velikoj dimenzionalnosti skupa podataka nad kojim se radi. Tačnije, nije problem sama dimenzionalnost podataka, već njena intrinzična dimenzionalnost. Intrinzična dimenzionalnost nekog skupa podataka se može gledati kao broj promenjivih potreban za minimalnu reprezentaciju tog skupa podataka. Postoje razne metode izračunavanja intrinzične dimenzionalnosti nekog skupa podataka. One se ugrubo dele na one za izračunavanje globalne intrinzične dimenzionalnosti i lokalne [2] intrinzične dimenzionalnosti nekog skupa podataka. Globalne metode gledaju celokupni skup podataka i njegovu intrinzičnu dimenzionalnost, dok se lokalne metode fokusiraju na manji podskup tih podataka.

Pri analizi grafa k najbližih suseda skupa podataka, može se primetiti da svi čvorovi imaju izlazni stepen k , ali ulazni stepen može značajno varirati. Ova varijacija može dovesti do prisustva čvorova sa značajno višim ulaznim stepenom od k , što se često označava kao prisustvo *hub*-ova.

Rad [1] je pokazao kako visoka globalna intrinzična dimenzionalnost može dovesti do pojave *hub*-ova u skupu podataka.

Ovaj rad će se baviti lokalnom intrinzičnom dimenzionalnošću i njenim uticajem na mašinsko učenje. Prvobitno će biti analizirana korelacija između lokalne intrinzične dimenzionalnosti i *hubness* vrednosti. Uvideće se negativna korelacija između ove dve vrednosti koja će ukazivati na moguće primene kombinacije ove dve vrednosti za poboljšanje nekih aspekata mašinskog učenja. Na kraju će biti prikazano unapređenje kNN klasifikatora korišćenjem kombinacije vrednosti lokalne intrinzične dimenzionalnosti i *hubness*-a.

Ovom prilikom zahvaljujem mom mentoru profesoru Miloš Radovanoviću za veliku pomoć i odličnu saradnju tokom izrade ovog rada, kao i na brzim odgovorima na sva moguća pitanja.

Sadržaj

1	Uvod	4
2	Osnovni koncepti	6
2.1	Skup podataka	7
2.2	Dimenzionalnost skupa podataka	8
2.2.1	Intrinzična dimenzionalnost	8
2.2.2	Lokalna intrinzična dimenzionalnost	8
2.3	Klasifikacija u mašinskom učenju	9
2.3.1	kNN klasifikator	9
2.4	<i>Hubness</i>	10
2.5	<i>Outlier</i>	10
2.5.1	kNN u pronalaženje <i>outlier</i> -a	11
2.5.2	<i>Local outlier factor</i>	11
3	Obrada podataka	14
3.1	Alkoholisanost i akcelerometarski podaci	15
3.2	Dexter skup podataka	15
3.3	Skupovi podataka koji nisu obrađivani u svrhu ovog rada	15
4	Korelacija između LID i <i>hubness</i>	20
4.1	Računanje <i>hubness</i> -a	21
4.2	Računanje lokalne intrinzične dimenzionalnosti	22
4.3	Rezultati	22
5	Primene LID i <i>hubness</i> u mašinskom učenju	26
5.1	kNN klasifikator	27
5.2	<i>Hubness</i> kNN klasifikator	28
5.3	LID kNN klasifikator	29

5.4	LID i <i>hubness</i> kNN klasifikator	30
5.5	Rezultati poređenja klasifikatora	31
5.6	Pronalaženje <i>outlier</i> -a	36
6	Zaključak	40

Uvod

U mašinskom učenju, pogotovo u skorije vreme, koriste se sve veći i veći skupovi podataka. Ne povećava se samo količina podataka već i njihova dimenzionalnost. Ova povećanja izazivaju velike probleme, i ne izgleda da će ovi porasti skupova podataka usporiti ili stati.

Jedna od bitnih osobina svakog skupa podataka je njegova dimenzionalnost i ona direktno utiče na njegovu veličinu. Dimenzionalnost predstavlja broj atributa nekog skupa podataka, ali neki atributi mogu nositi slične informacije pa samim tim biti suvišni. Zato nam je korisnija intrinzična dimenzionalnost. Intrinzična dimenzionalnost predstavlja minimalan broj promenjivih potreban da se neki skup podataka zapiše sa očuvanjem svih informacija. Intrinzična dimenzionalnost se može meriti globalno za ceo skup podataka ili lokalno za neki čvor.

Kada se priča o intrinzičnoj dimenzionalnosti korisno bi bilo gledati koncept *hubness*-a. *Hubness* vrednost nekog čvora predstavlja broj čvorova kojima je on najbliži sused u grafu najbližih suseda. Odnos između globalne intrinzične dimenzionalnosti i *hubness*-a je istražen u radu [1]. Odnos lokalne intrinzične dimenzionalnosti sa *hubness*-om nije u potpunosti istražen, iako može biti veoma koristan.

Intrinzična dimenzionalnost i *hubness* vrednost nekog skupa podataka mogu imati značajan uticaj na razne aspekte mašinskog učenja, međutim ovaj rad će se fokusirati na dva od ovih aspekata a to su klasifikacija i pronalaženje *outlier*-a. Klasifikacija predstavlja raspoređivanje podataka u klase. Jedan od poznatijih metoda klasifikacije je kNN klasifikator koji raspoređuje podatke na osnovu njihove sličnosti, to jest na osnovu njihovih k najbližih suseda. Pronalaženje *outlier*-a predstavlja pronalaženje podataka koji se značajno razlikuju od ostalih u nekom skupu podataka. Ovaj proces je veoma bitan jer čak i mali broj *outlier*-a u nekom skupu podataka može značajno uticati na performanse mnogih metoda mašinskog učenja

Cilj ovog rada je da istraži odnos lokalne intrinzične dimenzionalnosti i *hubness*-a na mašinsko učenje, i da pokuša da unapredi kNN klasifikator na osnovu dobijenih zaključaka.

Naredno poglavlje će predstaviti neke osnovne koncepte koji će biti potrebni za dalje razumevanje ovog rada. Potom će biti predstavljene obrade podataka koje su primenjivane nad podacima korišćenim u radu. Četvrto poglavlje će izneti metod i rezultate analize korelacije između lokalne intrinzične dimenzionalnosti i *hubness*-a. Peto poglavlje će prikazati moguće primene saznanja dobijenih u ovom radu na neke aspekte mašinskog učenja. Konačno u šestom poglavlju biće iznet zaključak ovog rada.

Osnovni koncepti

Oblast mašinskog učenja je prostrana i sadrži veliku količinu koncepata koji možda nisu poznati svim čitaocima ovog rada. Zato će ovo poglavlje predstaviti osnovne koncepte potrebne za razumevanje ostatka ovog rada i njegovih zaključaka, na uticaj intrinzične dimenzionalnosti na mašinsko učenje. Da bi se čitaoci pripremili za naredna poglavlja ovde će biti pređeni koncepti skupa podataka i njegove dimenzionalnosti, globalne i lokalne intrinzične dimenzionalnosti, klasifikacije i *outlier*-a.

Na samom početku poglavlja biće predstavljen skup podataka u kontekstu mašinskog učenja. Obradiće se sam pojam skupa podataka, tipovi vrednosti u skupu podataka, moguća reprezentacije skupa podataka i najčešće korišćeni format.

Naredni deo poglavlja baviće se dimenzionalnošću skupova podataka. Ovde će se obraditi pojam dimenzionalnosti skupa podataka, njen uticaj na mašinsko učenje kao i izazovi koje ona prouzrokuje. Poseban značaj biće dat intrinzičnoj dimenzionalnosti i lokalnoj intrinzičnoj dimenzionalnosti. Obradićemo same pojmove kao i njihov značaj za mašinsko učenje.

Nakon toga sledi obrada klasifikacije u mašinkom učenju, šta je ona i za šta služi. Takođe će biti pokriven kNN klasifikator i sam metod najbližih suseda, pošto će veliki fokus ostatka ovog rada biti na njemu. Biće pokriveno kako ovaj klasifikator radi, kao i neke od njegovih prednosti i mana.

Posle koncepata dimenzionalnosti i kNN klasifikatora kao nastavak biće pokriven koncept *hubness*-a: šta je on, kako se računa i njegov uticaj na mašinsko učenje.

Na kraju poglavlja obrađen je koncept *outlier*-a, šta on predstavlja, mogući uzroci njihove pojave kao i njihov uticaj na mašinsko učenje. Ovde će biti predstavljeni svi metodi za pronalaženje *outlier*-a koji će kasnije u radu biti korišćeni za poređenje performansi metoda predloženog u ovom radu. Biće objašnjen osnovni koncept rada ovih metoda i tačan način na koji oni određuju *outlier*-e.

2.1 Skup podataka

U mašinskom učenju, skup podataka predstavlja neku kolekciju struktuiranih podataka nad kojima se mogu trenirati i testirati modeli. Oni predstavljaju osnovu nad kojom se svo istraživanje na polju mašinskog učenja zasniva. Kvalitet korišćenih skupova podataka značajno utiče na tačnost i performanse modela koji se nad njime trenira.

Suštinski skup podataka je kolekcija zasebnih unosa podataka, gde svaki unos predstavlja neko odvojeno merenje ili deo problema koji skup podataka predstavlja. Svaki unos se naziva instanca. Svaka instanca skupa podataka ima vrednosti koje su njoj dodeljene, te vrednosti se nazivaju atributi. Neki skupovi podataka mogu da imaju i vrednost klase. To je još jedan specijalan atribut koji predstavlja željenu vrednost koja bi trebala da se dobije kada se ta instanca prosledi modelu. Vrednost klase određuje šta neka instanca predstavlja.

Atributi mogu biti:

- **Nominalni** - Ovi atributi predstavljaju vrednosti koje nemaju prirodan redosled i ne mogu se direktno porediti. Sve vrednosti su samo kolekcije oznaka. Ovi atributi se jedino mogu porediti po tome da li su apsolutno identični ili ne.
Na primer to može biti isečak iz neke knjige, komentar sa društvenih mreža, boja automobila i njima slične vrednosti.
- **Ordinalni** - Ovi atributi predstavljaju vrednosti koje imaju neki poredak ali razdaljina između vrednosti nije definisana. Sabiranje i oduzimanje ovih vrednosti nema nikakvog smisla.
Kao primer možemo uzeti opisnu ocenu nečega: loše, dobro ili odlično
- **Intervalni** - Vrednosti ovih atributa imaju poredak i merena su u fiksni i jednakim jedinicama. Razlika neke dve vrednosti sada ima smisla ali zbir i proizvod nemaju jer ne postoji nulta vrednost.
Primer ovog tipa atributa može biti spoljna temperatura u stepenima celzijusa.
- **Razmerni** - Ovi atributi su slični intervalnim ali imaju određenu nultu vrednost. Ove vrednosti se tretiraju kao realni brojevi i sve operacije nad njima su dozvoljene.
Primer ove vrednosti može biti dužina ili količina nečega.

Svi skupovi podataka korišćeni u ovom radu imaju vrednost klase i predstavljeni su u vidu razmer-nih atributa. Oni koji nisu originalno bili u tom formatu, izmenjeni su da bi bili.

Skupovi podataka mogu se predstaviti u vidu tabela gde redovi predstavljaju instance a kolone predstavljaju attribute. U idealnom slučaju sve instance bi trebale imati vrednosti za sve attribute, ali usled greške ili loših merenja može doći do vrednosti koje nedostaju.

Postoji mnoga rešenja za slučajeve gde postoji manjak vrednosti, ali u ovom radu neće biti navođene pošto su svi skupovi podataka koji su korišćeni imali vrednosti za sve attribute u svakoj instanci.

Ako instance u nekom skupu podataka imaju dosta nula vrednosti za razne attribute, ti skupovi podataka se mogu čuvati u vidu "retke" tabele. U ovakvoj reprezentaciji sve nula vrednosti u nekoj instanci se ne zapisuju već se podrazumevaju. Na ovakav način se može uštedeti dosta prostora bez gubitka informacija.

Najčešći format čuvanja skupa podataka je *csv* (*Comma Separated Values*) format gde je svaka instanca zapisana u odvojenom redu. Svaki red ima vrednosti razdvojene nekim znakom, najčešće to je zarez, svaka od tih vrednosti predstavlja jedan od atributa te instance.

2.2 Dimenzionalnost skupa podataka

Skupovi podataka obično imaju veći broj atributa, i samim tim se na njihove instance može gledati kao tačke u više-dimenzionom prostoru, gde svaka dimenzija predstavlja jedan od atributa. Dimenzionalnost nekog skupa podataka predstavlja broj atributa u tom skupu podataka. Na primer, ako skup podataka ima četiri atributa, njegova dimenzionalnost bi bila četiri.

Dimenzionalnost ima značajan uticaj na performanse nekog algoritma mašinskog učenja. Veća dimenzionalnost može da daje detaljnije informacije o podacima i time pomogne algoritmu. Ona nosi i značajne rizike.

Sa porastom dimenzionalnosti raste i veličina podataka koje algoritam mora da obradi, što može da dovede do otežanog i sporijeg treniranja. Sam porast broja atributa može eksponencijalno da poveća vreme potrebno za treniranje nekog algoritma. Ovo ne mora biti problem ako su informacije koje se nalaze u svim atributima korisne i povećavaju performanse krajnjeg modela, ali ako nisu veća dimenzionalnost samo donosi štetu.

Visoka dimenzionalnost može ukazivati i da je skup podataka redak, to jest da veliki broj atributa ima ne nula vrednosti u malom procentu instanci. Ova pojava može izazvati značajne probleme pri treniranju model-a, jer postoji dosta atributa koji ne nose značajne informacije već samo zbunjuju algoritam.

Izazovi koje uzrokuje visoka dimenzionalnost skupa podataka se često naziva prokletstvo dimenzionalnosti (*curse of dimensionality*), ovaj pojam je originalno imenovao Bellman-a (1961) [9]. Između ostalog ovaj pojam ima značajan uticaj na metod najbližih suseda. Postoje razne metode čiji je cilj smanjenje dimenzionalnost, sa očuvanjem što više informacija sadržanih u originalnim podacima.

2.2.1 Intrinzična dimenzionalnost

Kada se gleda dimenzionalnost, gleda se broj atributa nekog skupa podataka, ali taj podatak može da zavara i da utisak postojanja mnogo veće količine informacija od one stvarne. Mnogo bolja mera količine informacija koja je sadržana u nekom skupu podataka je intrinzična dimenzionalnost [12].

Intrinzična dimenzionalnost skupa podataka predstavlja minimalan broj promenljivih potreban da se zapiše ista količina informacija. Stvarni skupovi podataka često mogu biti predstavljeni u prostoru niže dimenzionalnosti, od dimenzionalnosti samog skupa podataka, pa intrinzična dimenzionalnost može biti dosta manja od same dimenzionalnosti.

Kao što je navedeno u 2.2 velika dimenzionalnost nosi značajne rizike, tako da ako postoji mogućnost za smanjenjem dimenzionalnosti skupa podataka, bez gubitka informacija, dobiće se bolji i efikasniji model.

2.2.2 Lokalna intrinzična dimenzionalnost

Pošto su realni skupovi podataka retko kada uniformni, intrinzična dimenzionalnost svih podskupova podataka glavnog skupa podataka ne mora biti međusobno jednaka niti jednaka intrinzičnoj dimenzionalnosti glavnog skupa podataka, što dovodi do postojanja lokalne intrinzične dimenzionalnosti. Lokalna intrinzična dimenzionalnost (u daljem tekstu LID) [2] predstavlja intrinzičnu dimenzionalnost nekog podskupa podataka, gledanog skupa podataka.

Lokalna intrinzična dimenzionalnost je u radu [10] prikazana kao ekvivalent pojmu diskriminabilnosti mere udaljenosti, koja se ogleda u stopi rasta kumulativne distribucione funkcije.

Neka X predstavlja nasumično odabranu promenjivu razdaljine, neprekidne kumulativne distribucione funkcije F_X . Onda je udaljenost do k -tog najbližeg suseda u uzorku od n tačaka estimacija razdaljine r za koju važi:

$$F_X(r) = k/n$$

Ako je k fiksno dok n teži u beskonačno, nediskriminabilnost F_X na razdaljini od k -tog najbližeg suseda teži lokalnoj intrinzičnoj dimenzionalnosti [2].

2.3 Klasifikacija u mašinskom učenju

Klasifikacija je jedna od osnovnih oblasti mašinskog učenja. Ona podrazumeva raspoređivanje instanci u ranije predodređene skupove koji se nazivaju klase. Dobar primer klasifikacije bi bilo raspoređivanje mejlova u one koji jesu i one koji nisu *spam*. Moguće vrednosti klase moraju biti određene pre početka treniranja klasifikacionog modela.

Kao što je rečeno u 2.1 neki skupovi podataka dolaze sa atributom koji predstavlja vrednost klase. Ovakvi skupovi podataka se koriste za treniranje klasifikacionih modela. Kada se klasifikacioni model istrenira on će svaku instancu koja mu se prosledi na prepoznavanje klasifikovati u jednu od klasa koje ima.

2.3.1 *kNN* klasifikator

U ovom radu veliki fokus biće na jednom specifičnom metodu klasifikacije. Taj metod je metoda najbližih suseda [11]. Ovo je jedan od najjednostavnijih i intuitivnijih metoda klasifikacije, ali ta jednostavnost nema loš uticaj na njegove performanse. Ovaj metod radi na principu da su slične instance blizu jedna drugoj.

Metod najbližih suseda radi na sledeći način:

- Pri treningu ne postoji neki kompleksan algoritam po kome se uči, već se samo sve instance skupa podataka čuvaju kao trening skup.
- Kada treba da se klasifikuje nova instanca, računa se razdaljina te instance od svih instanci u trening skupu, koristeći neku meru razdaljine na primer euklidsku razdaljinu. Potom se određuje k najbližih suseda prosleđene instance.
- Na kraju se predviđa vrednost klase prosleđene instance, glasanjem između k najbližih suseda. Glasanje podrazumeva uzimanje vrednosti klase k najbližih suseda i vraćanjem najzastupljenije vrednosti. Na primer ako 2 od 3 najbliža suseda pripadaju klasi A, onda i prosleđena instanca pripada klasi A.

Izbor broja praćenih najbližih suseda, najčešće predstavljeno sa k , je veoma bitan i u značajnoj meri utiče na performanse klasifikatora. Manje k može dovesti do pojave *overfitting*-a, to jest prevelikog prilagođavanja klasifikatora trening podacima. Dok velika vrednost k može dovesti do gubljenja bitnih informacija i uključivanja predalekih instanci u proces glasanja.

Veoma velika prednost ovog metoda je njegova jednostavnost, kako za razumevanje tako i za implementaciju. Činjenica da nema potrebe za treniranjem se takođe može gledati kao prednost ovog metoda, jer ovaj korak obično zahteva veliku količinu vremena.

Pošto se pri svakom predviđanju moraju računati razdaljine do svih instanci trening skupa, ovaj proces može postati veoma zahtevan kod većih skupova podataka. Zbog načina na koji ovaj metod radi on može biti veoma osetljiv na prisustvo *outlier*-a koji mogu značajno uticati na računanje razdaljina

2.4 *Hubness*

Kada se govori o skupovima podataka visoke dimenzionalnosti i metodu najbližih suseda, teško se može preskočiti pojam *hubness*-a [1]. Ovaj pojam predstavlja tendenciju nekih čvorova da se neočekivano često pojavljuju u najbližim susedima drugih čvorova. U grafu k najbližih suseda svaki čvor mora imati tačno k najbližih suseda, to jest k izlaznih grana, ali ako gledamo koliko puta se neki čvor pojavljuje u k najbližih suseda drugih čvorova, to jest broj ulaznih grana tog čvora, taj broj može biti mnogo veći, pa samim tim i mnogo manji za neke čvorove. Kada je broj ulaznih grana nekog čvora u grafu k najbližih suseda mnogo veći od k taj čvor se smatra *hub*-om. Nasuprot tome kada je broj ulaznih grana nekog čvora u grafu k najbližih suseda mnogo manji od k taj čvor se smatra *antihub*-om.

Hub-ovi i *antihub*-ovi mogu značajno da utiču na performanse metoda najbližih suseda, time što će imati neočekivano veliki uticaj, za jednu instancu, na sve rezultate ovog metoda. *Hub*-ovi će biti previše predstavljeni u rezultatima, samim tim potiskujući neke druge čvorove koji bi nam omogućili da bolje diskriminiramo podatke.

Hubness se računa u dva koraka:

1. Konstruišemo graf k najbližih suseda za neki skup podataka, na osnovu odabrane metrike udaljenosti.
2. Za svaki čvor grafa k najbližih suseda odredimo koliko se puta on pojavljuje u k najbližih suseda drugih čvorova grafa, to jest odredimo njegov ulazni stepen.

2.5 *Outlier*

Outlier se može definisati kao instanca koja se razlikuje od svih ostalih instanci u tolikoj meri da izaziva sumnju da ju je izgenerisao neki drugačiji mehanizam od ostatka instanci [8].

Postoji šansa da neki *outlier*-i potiču od stvarnih izuzetaka, ali često oni potiču iz grešaka prilikom prikupljanja ili obrađivanja podataka. Na primer kvarovima opreme za merenje.

Outlier-i mogu značajno da utiču na neke statističke mere koje se koriste za analizu podatka, kao što su prosek i koeficijent korelacije. Oni takođe mogu značajno da pokvare rezultate modela koji se koriste za mašinsko učenje, tako što ga nateraju da se prilagodi njima iako oni nisu istinski reprezentativne instance.

Outlier-i mogu da proizilaze iz raznih izvora:

- Greške u merenjima - kao što je već rečeno kvarovi u opremi kao i nepravilnosti u samom načinu skupljanja podataka mogu proizvesti greške u merenjima.
- Greške u unosu podataka - ako su podaci ručno uneti, uvodi se mogućnost ljudske greške.
- Greške u obradi podatka - svaka obrada podataka nosi rizik od greške koja može da pokvari podatke.

- Ispravni ali izuzetni podaci - Uvek postoji mogućnost da je poreklo nekog *outlier*-a neka izuzetna situacija i u tom slučaju on je ispravan podatak.

Postoji mnogo tehnika za pronalaženje *outlier*-a, ali većina njih je zasnovana na verovatnoći [5].

Tehnike koje će biti korišćene u daljem radu su metod k-najbližih suseda (kNN) i *local outlier factor* (LOF).

2.5.1 kNN u pronalaženje outlier-a

Korišćenje kNN metoda [13] za pronalaženje *outlier*-a se zasniva na ideji da su *outlier* čvorovi značajno udaljeniji od svojih najbližih suseda u odnosu na većinu čvorova u kNN grafu nekog skupa podataka. Kao i kod klasifikacije ovaj metod je veoma prost i intuitivan ali uprkos tome i dalje daje veoma dobre rezultate u većini slučajeva.

Osnovni koncept rada ovog metoda je sledeći:

- Za svaku instancu u skupu podataka, izračuna se njena udaljenost od svih ostalih instanci. Za udaljenost se uzima metrika po izboru, na primer euklidska razdaljina.
- Odredi se k najbližih suseda za svaku od instanci na osnovu prethodno izračunatih razdaljina, čime dobijamo graf k najbližih suseda.
- Izvlače se prosečna udaljenost u odnosu na svoje susede ili udaljenost od najdaljeg od svojih k najbližih suseda za svaki čvor grafa.
- Čvorovi koji imaju značajno veću vrednost izvučenu u prošlom koraku se označavaju kao *outlier*-i.

2.5.2 Local outlier factor

Local outlier factor [14] je nastao iz proste ideje da biti *outlier* nije binarna osobina nekih podataka, već da ima smisla odrediti stepen u kom je neki podatak *outlier*. Taj stepen u kojem je neki podatak *outlier* predstavlja *local outlier factor* tog podatka. Ova mera je lokalna jer stepen zavisi od toga koliko je podatak izolovan u svom susedstvu.

LOF se računa na osnovu lokalne gustine instanci, koja zavisi od k najbližih suseda. Lokalna gustina se dobija iz lokalnih regiona koji se određuju na osnovu udaljenosti k-tog najbližeg suseda, gde svi čvorovi koji se nalaze na toj ili manjoj udaljenosti spadaju u lokalni region čvora. Poređenjem tih gustina tih lokalnih regiona, mogu se naći regioni sa sličnim gustinama i oni sa znatno manjim gustinama. Oni čvorovi koji imaju znatno manje gustine se smatraju *outlier*-ima. Sledeće definicije date u radu [14] se koriste za izračunavanje LOF vrednosti neke instance skupa podataka:

Za svaki pozitivan broj k, k-razdaljina objekta p, koja se označava sa k-razdaljina(p), je:

$$k\text{-razdaljina}(p) = d(p, o) \quad \text{takva da važi:}$$

- (i) za bar k objekata $o' \in D \setminus \{p\}$, $d(p, o') \leq d(p, o)$
- (ii) za najviše $k - 1$ objekata $o' \in D \setminus \{p\}$, $d(p, o') < d(p, o)$

Gde $d(p, o)$ predstavlja razdaljinu između objekata p i o po nekoj meri razdaljine. Drugim rečima k-razdaljina je udaljenost od najudaljenijeg od k najbližih suseda.

N_k označava skup čvorova koji spadaju u lokalni region nekog čvora p na osnovu k -razdaljine(p)

$$N_k(p) = \{q \in D \setminus \{p\} \mid d(p, q) \leq k\text{-razdaljina}(p)\}$$

Razdaljina dostižnosti objekta p od objekta o je jednaka pravoj razdaljini između ta dva objekta, ako je ona veća od k -razdaljine od p . Ako je prava razdaljina objekata p i o manja od k -razdaljine od p onda je njihova razdaljina dostižnosti jednaka k -razdaljini od p .

$$\text{razdaljina-dostižnosti}_k(p, o) = \max\{k\text{-razdaljina}(o), d(p, o)\}$$

Lokalna gustina dostižnosti nekog objekta p je definisana kao inverzni prosek razdaljine dostižnosti objekta p od svojih suseda. Ovo predstavlja razdaljinu dostižnosti objekta p od svojih suseda.

$$\text{lrd}_k(p) = 1 \div \left(\frac{\sum_{o \in N_k(p)} \text{razdaljina-dostižnosti}_k(p, o)}{|N_k(p)|} \right)$$

Na kraju se lokalna gustina dostižnosti objekta p poredi sa lokalnim gustinama dostižnosti suseda objekta p da bi se odredila LOF vrednost za objekat p . Ova računica se izvodi na osnovu sledeće formule:

$$\text{LOF}_k(p) = \frac{\sum_{o \in N_k(p)} \frac{\text{lrd}_k(o)}{\text{lrd}_k(p)}}{|N_k(p)|}$$

- $\text{LOF}(k) > 1$ - označava nižu gustinu u odnosu na susede, pa samim tim i da je čvor *outlier*
- $\text{LOF}(k) \approx 1$ - označava sličnu gustinu u odnosu na susede
- $\text{LOF}(k) < 1$ - označava veću gustinu u odnosu na susede

Obrada podataka

Podaci koji su korišćeni tokom izrade ovog rada potiču iz javno dostupnih skupova podataka. Izuzet skupova podataka korišćenih za *outlier* detekciju, svi skupovi podataka originalno potiču sa *UCI* [4] baze. Dok skupovi podataka korišćeni za pronalaženje *outlier* potiču iz rada [5]. Uzimane su verzije skupova podataka sa svim transformacijama koje su objavljene uz rad. Neki od ovih podataka su bili već spremni za korišćenje jer su već bili lepo formatirani i numerički, dok su drugi zahtevali dalju obradu. Sve obrade podataka koje su bile rađene u svrhu ovog rada će u nastavku biti opisane. Dve trećine skupova podataka su dobijene od strane profesora Miloša Radovanovića, ali takođe originalno potiču sa *UCI* baze.

U ovom poglavlju prvo će biti opisana obrada skupa podataka *bar crawl* da bi se doveo u format potreban za korišćenje u ostatku rada. Potom će biti opisane obrade *dexter* skupa podataka sa istim ciljem.

Nakon toga u naslovu 3.3 biće dat kratak opis svih preostalih skupova podataka korišćenih u radu. Ovde postoji par skupova podataka čiji je opis izostavljen, razlog za to je što izvor sa kojeg su ovi skupovi podataka dobavljeni nije sadržao dovoljno informacija.

Na kraju ovog poglavlja može se naći tabela 3.1 sa osnovnim podacima za sve skupove podataka koji su korišćeni u ovom radu.

3.1 Alkoholisanost i akcelerometarski podaci

Ovo su podaci korišćeni u radu [3]. Po rečima autora ovih podataka oni su prvobitno prikupljeni od 19 učesnika. Međutim podaci 6 učesnika su morali biti odbačeni tako da ovaj skup podataka sadrži podatke od preostalih 13 učesnika. Uključeni su akcelerometarski podaci prikupljeni sa pametnih telefona pri brzini uzorkovanja od 40Hz. Transdermalni sadržaj alkohola je prikupljan pomoću SCRAM narukvica u intervalima od 30 minuta. Ovde su korišćeni "očišćeni" podaci za sadržaj alkohola, to jest podaci koji su filtrirani *zero-phase low-pass* filterom i pomerani unazad za 45 minuta kako bi se preciznije odražavala stvarna intoksikacija učesnika. Do sada navedena obrada podataka je izvršena od strane samog autora i rezultovala je u jednom fajlu koji sadrži akcelerometarske podatke za svakog od učesnika sa vremenima uzorkovanja i odvojenim fajlovima sa podacima o njihovom sadržaju alkohola.

Da bi se ovi podaci pripremili za klasifikaciju korisćen je isti princip kao i u njihovom izvornom radu. Napisan je PySpark kod koji učitava sve ove fajlove i zadržava samo podatke gde je sadržaj alkohola veći od 0,08 zato što to računamo kao granicu pijanstva. Potom ujedinjuje sve odvojene podatke o korisnicima i potom ih spaja sa akcelerometarskim podacima. Prilikom tog spajanja radi se spajanje po korisniku na levo to jest spajanje se vrši samo nad poljima koja postoje u akcelerometarskim podacima. Na kraju se zadržavaju samo one kombinacije podataka koje imaju vremensku razliku manju od 10 sekundi između vremena očitavanja spojenih strana.

Ovim procesom dobijamo skup podataka sa 116 886 instanci i 5 atributa. Ovaj skup podataka će u ostatku rada biti nazivan *bar crawl*.

3.2 Dexter skup podataka

Dexter je skup podataka u vidu klasifikaciji teksta u "*bag-of-words*" reprezentaciji. Dexter je skup podataka klasifikovan u dve klase.

Ovaj skup podataka je podeljen na dva fajla, u jednom su vrednosti klase a u drugom vrednosti atributa svake instance. Da bi se ovi podaci spojili prvo se pravi matrica, u vidu niza od 300 elemenata koji su i sami nizovi sa 20000 nula. Potom se čitaju vrednosti za klase i upisuju se na nulto mesto svakog od podnizova. Vrednosti atributa su čuvani tako što u svakom redu stoje vrednosti za jednu instancu odvojene razmacima. Svaka od vrednosti u redu su predstavljeni u paru brojeva koji su razdvojeni dvotačkom, gde prvi broj predstavlja atribut a drugi broj predstavlja vrednost. U svakom redu nula vrednosti su izostavljene, što znači da svi ne pomenuti atributi imaju vrednost nula, zbog toga je na početku matrica popunjena nulama. Pri čitanju vrednosti atributa svaki red se parsira i vrednosti koje su u njemu se stavljaju u podmatricu koja odgovara broju reda na mesto koje odgovara broju atributa. Primera radi, ako u prvom redu jedna od vrednosti je 5:30 ta vrednost će se u matrici naći na mestu $m[0][5] = 30$. Na kraju matrica se zapisuje u csv fajl koji se posle koristi pri proračunima.

3.3 Skupovi podataka koji nisu obrađivani u svrhu ovog rada

Većina skupova podataka koji su korišćeni u ovom radu nisu zahtevali dalje obrade, jer su već bili u željenom formatu ili su već bili podloženi obradi navedenoj u radu [1]. Ti skupovi su korišćeni u istom formatu u kom su i nabavljeni za svrhe ovog rada. U ove skupove ubrajamo i skupove koji su zahtevali samo dodavanje zaglavlja.

U nastavku će svi preostali skupovi podataka koji su korišćeni biti ukratko opisani:

- “Wine classified by quality” - Ovaj skup podataka se sastoji iz rezultata fizičko-hemijskih testova nad uzorcima crvenih i belih vina iz severnog Portugala. On je namenjen za klasifikaciju tih vina na osnovu njihovog kvaliteta. Instance ovog skupa podataka nisu balansirane po klasama.
- “Banknote authenticity” - Podaci su izvučeni iz slika pravih i falsifikovanih uzoraka novčanica. Namenjeni su za klasifikaciju novčanica po tome da li su falsifikati ili nisu.
- “Shuttle” - STATLOG verzija ovog skupa podataka. Predstavlja problem klasifikacije gde je odnos klasa značajno ne balansiran. Dakle 80% instanci pripadaju jednoj klasi.
- “Iranian telecom customer churn” - Podaci su nasumično skupljeni od strane Iranske telekomunikacijske firme, tokom perioda od 12 meseci. Skup podataka sadrži podatke vezane za korisnike ove firme. Vrednost klase zavisi od toga da li je korisnik prestao da koristi usluge firme tokom praćenog perioda. Ovo je problem klasifikacije gde instance treba da se klasifikuju po tome da li je korisnik napustio firmu ili nije.
- “Taiwanese bankruptcy prediction” - Skup podataka je kreiran na osnovu podataka iz Tajvanskog ekonomskog časopisa za period od 1999. do 2009. godine. Bankrot kompanije je definisan na osnovu regulativa Tajvanske berze. Ovo je problem klasifikacija gde instance treba da se klasifikuju po tome da li je kompanija bankrotirala ili ne.
- “Dorothea” - Ovaj skup podataka predstavlja prvi korak u pronalaženju novih lekova, a to je određivanje jedinjenja koja se vezuju za željeni receptor. Hemijska jedinjenja treba klasifikovati po tome da li se vezuju ili ne vezuju za receptor, to jest da li su aktivna ili neaktivna.
- “Gisette” - Ovo je problem prepoznavanja ručno napisanih brojeva. Potrebno je prepoznati veoma slične ručno napisane brojeve “4” i “9”, što predstavlja problem klasifikacije.
- “Isolet” - Skup podataka je izgenerisan tako što je 150 učesnika izgovorilo naziv svakog slova u alfabetu po dva puta, potom je snimak parametrizovan procesom opisanim u radu [15]. Ovo je problem klasifikacije gde instance treba klasifikovati po tome koje slovo alfabeta predstavljaju.
- “Musk” - Ovaj skup podataka se sastoji od podataka za 102 molekula gde je svaki opisan sa 166 atributa. Cilj je klasifikovati ove molekule u *musk* i ne *musk* klase. Eksperti su odredili da su od 102 molekula 39 *musk* a preostalih 63 ne *musk*.
- “Abalone” - Svrha ovog skupa podataka je predviđanje starosti *abalone*-a na osnovu fizičkih merenja.
- “Arrhythmia” - Treba klasifikovati instance u 16 klasa na osnovu prisustva ili odsustva kardiovaskularnih aritmija.
- “Diabetes” - Ovo su podaci merenja raznih telesnih vrednosti pacijenata sa dijabetesom.
- “Echocardiogram” - Ovaj skup podataka predstavlja pacijente koji su preživeli srčani udar i sadrži podatak o tome koliko su poživeli posle srčanog udara. Ovo je problem klasifikacije gde treba odrediti da li će neki pacijent poživeti godinu dana posle srčanog udara na osnovu ostalih atributa.
- “Glass” - Ovaj skup podataka je nastao skupljanjem podataka iz forenzičke službe SAD-a. Sadrži 6 tipova stakla definisanih na osnovu svog sadržaja oksida. Svaki tip stakla predstavlja po jednu klasu i treba sve instance klasifikovati po tome.

- “Haberman” - Sastoji se od podataka iz studije izvršene između 1958. i 1970. godine. Ova studija se bavila istraživanjem broja preživelih pacijenata koji su išli na operaciju dojke. Ovde pacijente treba klasifikovati po tome da li su preživeli pet ili više godina.
- “Ionosphere” - Klasifikacija povratnog signala radara iz jonosfere. Potrebno je klasifikovati instance na dobre i loše povratne signale radara.
- “Iris” - Ovo je jedan od najstarijih skupova podataka korišćenih u literaturi za klasifikaciju. Ovo je problem klasifikacije cveta perunike u tri klase na osnovu tipa tog cveta.
- “Lung Cancer” - Skup podataka sadrži opise tri vrste patološkog raka pluća. Potrebno je klasifikovati instance po vrsti raka pluća koji predstavlja.
- “Mfeat” - Ovde postoji šest skupova podataka od kojih svi predstavljaju istu stvar ali parametrizovanu na različite načine. Podaci se sastoje od ručno pisanih brojeva od 0 do 9 izvučenih iz holandskih komunalnih mapa.
- “mini_newsgroups-m” - Parametrizovana kolekcija dokumenata sa diskusionih foruma.
- “moviereviews-sorted-m-norm-tf” - Parametrizovane recenzije od 2000 filmova.
- “Optdigits” - Ovo je još jedan skup podataka namenjen prepoznavanju ručno napisanih brojeva.
- “Ozone” - Ovo su dva skupa podataka o nivou prizemnog ozona. Ova dva skupa podataka se dele na osmočasovni i jednočasovni skup podataka.
- “Parkinsons” - Ovaj skup podataka se sastoji iz snimaka glasa zdravih ljudi i ljudi sa Parkinsonovom bolešću. Potrebno je klasifikovati instance na one koje predstavljaju zdrave ljude i one koje predstavljaju bolesne ljude.
- “Pendigits” - Još jedan skup podataka koji sadrži ručno napisane brojeve koje treba prepoznati
- “Reuters-transcribed” - Skup podataka je kreiran čitanjem 200 fajlova iz 10 najvećih Rojtersovih klasa, potom je korišćeno prepoznavanje govora da se izgenerišu transkripti tih čitanja.
- “Segment” - Ovaj skup podataka je nastao iz 7 slika nekog pejzaža. Sve slike su podeljene u segmente i potom su instance nasumično izvlačene iz ih segmenata.
- “Sonar” - Skup podataka sadrži signale sonara odbijene od metalni cilindar i od kamenje. Cilj je klasifikovati instance na osnovu toga da li je signal odbijen od metalni cilindar ili kamen.
- “Spectrometer” - Infracrveni astronomski satelit (IRAS) je bio prvi pokušaj da se mapira infracrveno svetlo nad celim nebom. Ovaj skup podataka sadrži deo snimaka iz baze svih snimaka napravljenih tim satelitom.
- “Vehicle” - Treba klasifikovati siluetu vozila u jednu od četiri klase, gde svaka klasa predstavlja tip vozila. Atributi su izvučeni na osnovu siluete.
- “Vowel” - Skup podataka koji sadrži parametrizaciju izgovaranja samoglasnika izgovorenih od strane različitih govornika. Ovo je problem klasifikacije instanci u jednu od jedanaest klasa, gde svaka predstavlja jedan od samoglasnika engleskog jezika.
- “Wdbc” - Sastoji se od instanci koje predstavljaju parametrizovane slike fine iglene aspiracije (FNA) masa na dojci. Parametrizacija daje attribute koji opisuju karakteristike čeljkog jezgra prisutnog na slici.
- “Wdbc” - Svaka instanca predstavlja podatke o naknadnom pregledu pacijenta sa rakom dojke. Atributi su određeni na isti način kao i u prethodno skupu podataka.

Naziv skupa podataka	Broj instanci	Broj atributa
Wine classified by quality	4898	11
Banknote authenticity	1373	5
Shuttle	58000	10
Bar crawl	116886	5
Iranian telecom customer churn	3150	14
Taiwanese bankruptcy prediction	6819	97
Dexter	300	20000
Dorothea	800	6061
Gisette	6000	5000
Isolet	7797	617
Musk	6598	166
Abalone	4177	8
Arrhythmia	452	279
Diabetes	768	8
Echocardiogram	131	7
Ecoli	336	7
Glass	214	9
Haberman	306	3
Ionosphere	351	34
Iris	150	4
Lung Cancer	181	12533
Mfeat factors	2000	216
Mfeat fourier	2000	76
Mfeat karhunen	2000	64
Mfeat morph	2000	6
Mfeat pixel	2000	240
Mfeat zernike	2000	47
mini_newsgroups-m	1999	7827
moviereviews-sorted-m-norm-tf	2000	11885
Optdigits	5620	64
Ovarian	253	15154
Ozone eighthr	2534	72
Ozone onehr	2536	72
Page blocks	5473	10
Parkinsons	195	22
Pendigits	10992	16
Reuters-transcribed	201	3029
Segment	2310	19
Sonar	208	60
Spectf	267	44
Spectrometer	531	100
Vehicle	846	18
Vowel	990	10
Wdbc	367	32
Wpbc	198	32
Yeast	1484	8

Tabela 3.1: Svi skupovi podataka sa brojem instanci i atributa

Korelacija između LID i *hubness*

U radu [1] je pokazano da visoka intrinzična dimenzionalnost podataka dovodi do pojave *hub*-ova i da postoji značajna korelacija između intrinzične dimenzionalnosti i *hubness* vrednosti. Taj rad se odnosio na globalnu intrinzičnu dimenzionalnost i njenu korelaciju sa *hubness* vrednosti, ali odnos *hubness* vrednosti i lokalne intrinzične dimenzionalnosti nije istražen. Na osnovu toga što postoji korelacija između intrinzične dimenzionalnosti i *hubness* vrednosti može se očekivati da postoji neki odnos između lokalne intrinzične dimenzionalnosti i *hubness* vrednosti. Ovo poglavlje će se baviti istraživanjem tog odnosa.

Korelacija između LID i *hubness* ukazuje na odnos između ova dva parametra, pa će rezultati ovog poglavlja biti korišćeni u budućim poglavljima. Za računanje korelacije potrebne su vrednosti LID i *hubness* za svaki čvor u skupu podataka. U ovom poglavlju će biti pređen proces izračunavanja tih vrednosti i konačni rezultat tih proračuna. Takođe će radi provere tačnosti biti izračunati *skewness* i globalna intrinzična dimenzionalnost svakog skupa podataka da bi se uporedili sa rezultatima iz rada [1]. Svi proračuni su rađeni za vrednosti k od 20, 40, 60, 80 i 100.

Prvi deo ovog poglavlja predložiće način računanja *hubness* vrednosti čvorova nekog skupa podataka korišćen u ovom radu. Takođe ovde će biti prikazan način na koji je računat *skewness hubness* vrednosti nekog skupa podataka.

Potom će biti objašnjen način računanja LID vrednosti čvorova nekog skupa podataka, kao i kratak opis svih algoritama korišćenih u ovom radu. Ovde će biti pokriven i metod na koji je izvučena vrednost globalne intrinzične dimenzionalnosti za neki skup podataka iz LID vrednosti njegovih čvorova.

Na kraju će biti prikazan način na koji je dobijen konačni rezultat korelacije između LID i *hubness*, kao i poređenje dobijenih rezultata sa onima iz rada [1]. Ovde će u tabelama biti prikazani svi rezultati računa korelacije između LID i *hubness* i izvučeni neki zaključci iz njih.

4.1 Računanje *hubness*-a

Hubness predstavlja ulazni stepen svakog čvora u grafu k najbližih suseda. Za računanje ulaznog stepena korišćene su dve *python* biblioteke, a to su *scikit-learn* i *networkx*. Prvo se napravi graf najbližih suseda koristeći metode iz *scikit-learn*, potom se taj graf učitava u *networkx*. Posle učitavanja grafa, *networkx* ima funkciju koja vraća ulazni stepen svakog čvora. Rezultati se zapisuju u listu gde svaki element predstavlja *hubness* vrednost čvora pod rednim brojem jednakom indeksu tog elementa.

Lista ulaznih stepeni se takođe koristi za računanje *skewness* vrednosti. Ova vrednost će se kasnije koristiti za proveru tačnosti svih proračuna.

Skewness se računa na sledeći način:

- Prvo se računa srednja vrednost (*mean*) liste ulaznih stepeni:

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i$$

gde je n broj čvorova, a x_i ulazni stepen svakog čvora.

- Zatim se računa standardna devijacija (*standard deviation*):

$$\sigma = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2}$$

gde je μ prethodno izračunata srednja vrednost.

- Nakon toga, računa se treći momenat:

$$\text{Treći momenat} = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^3$$

Ova vrednost opisuje asimetriju distribucije ulaznih stepeni.

- Na kraju, *skewness* se računa kao:

$$\text{Skewness} = \frac{\text{Treći momenat}}{\sigma^3}$$

gde je σ^3 standardna devijacija podignuta na treći stepen.

Vrednosti *skewness* se čuvaju u promenljivoj, pa se potom skupljaju u listu vrednosti za sve skupove podataka.

4.2 Računanje lokalne intrinzične dimenzionalnosti

Za računanje LID korišćena je *python* biblioteka *scikit-dimension* [6]. Testirana su tri algoritma za računanje lokalne intrinzične dimenzionalnosti:

1. LPCA (*Local Principal Component Analysis*)

Ovaj algoritam koristi lokalnu analizu glavnih komponenti (PCA) kako bi procenio lokalnu dimenzionalnost prostora. Na osnovu lokalnog okruženja svake tačke izračunava broj dimenzija koji je potreban da bi se opisala varijabilnost podataka.

2. MLE (*Maximum Likelihood Estimation*)

Algoritam za procenu maksimalne verodostojnosti koristi statističke metode kako bi izračunao intrinzičnu dimenzionalnost. MLE pristup se zasniva na proceni verovatnoće da se podaci nalaze u prostoru određene dimenzionalnosti.

3. TLE (*Tight Local intrinsic dimensionality Estimator*) [7]

Estimator primenjuje MLE tehnike i teoriju ekstremnih vrednosti, da bi dao rezultate i nad malim skupovima od samo 20 tačaka.

Rezultati sva tri algoritma su skupljeni u tri liste i za svaki je odvojeno izračunata korelacija.

Za svaki skup podataka izračunat je i prosek LID vrednosti svih instanci da bi se dobila vrednost globalne intrinzične dimenzionalnosti, koja će se kasnije koristiti za proveru tačnosti rezultata.

4.3 Rezultati

Da bi se dobio krajnji rezultat izračunava se Pearson-ov koeficijent korelacije između *hubness* i LID vrednosti svake instance u skupu podataka. Takođe se računa i Pearson-ov koeficijent korelacije za vrednosti *skewness* i intrinzične dimenzionalnosti u svim skupovima podataka kao kontrolni rezultat i u svrhe poređenja sa lokalnim vrednostima. Ovaj rezultat predstavlja korelaciju između globalnih vrednosti za ceo skup podataka.

Kontrolni rezultat je vratio vrednosti od 0,62 do 0,66 u zavisnosti od korišćenog *k*. Kontrolni rezultat je sličan rezultatu od 0,62 dobijenom u radu [1]. Male razlike između ta dva rezultata mogu se pripisati tome što su neki od skupova podataka koji su korišćeni različiti i tome što je u navedenom radu korišćen Spearman-ov koeficijent korelacije, kao i druga vrednost za *k*.

U tabelama 4.1, 4.2 i 4.3 se mogu videti rezultati korelacije između *hubness* i LID. Pregledom konačnih rezultata može se primetiti da za LPCA i TLE postoji dosta nan vrednosti, njihov uzrok su problemi u implementaciji tih algoritama u *scikit-dimension* biblioteci, zato će se u nastavku rada koristiti isključivo MLE algoritam. U svim rezultatima može se primetiti slaba negativna korelacija između *hubness* i LID vrednosti, što daje naznake da se kombinacijom ova dva metoda može doći do neke njihove korisne primene. O ovome će biti više reči u nastavku rada.

Ako se pogledaju rezultati korelacije između globalne intrinzične dimenzionalnosti i *skewness*-a možemo primetiti značajan kontrast tih rezultata i onih lokalnih. Dakle globalno postoji pozitivna korelacija i to značajna pozitivna korelacija, dok ako pogledamo lokalno na pojedinačne čvorove dobijamo slabu negativnu korelaciju.

Naziv skupa podataka	K=20			K=40		
	LPCA	MLE	TLE	LPCA	MLE	TLE
Wine classified by quality	0.1863	-0.1113	-0.1137	0.2723	-0.0908	-0.0611
Banknote authenticity	0.1509	0.0125	0.0087	0.1368	0.1202	0.0822
Shuttle	0.1953	-0.3302	nan	0.2156	-0.4249	nan
Bar crawl	0.0109	-0.2136	nan	-0.0094	-0.3557	nan
Iranian telecom customer churn	0.0965	-0.2655	nan	0.1241	-0.2741	nan
Taiwanese bankruptcy prediction	-0.0469	-0.0348	nan	-0.0665	-0.0343	nan
Dexter	nan	-0.1854	-0.1630	nan	-0.2225	-0.1932
Dorothea	-0.1549	-0.3934	-0.2771	0.1672	-0.5012	-0.5151
Gisette	nan	0.0708	0.1211	nan	0.1125	0.1766
Isolet	0.1211	-0.2114	-0.1069	0.2499	-0.2925	-0.1636
Musk	0.0475	-0.1649	-0.0920	0.1404	-0.1885	-0.1151
Abalone	0.2646	-0.3341	-0.1152	0.2461	-0.3420	-0.0869
Arrhythmia	0.3303	-0.4320	-0.0906	0.3262	-0.5475	-0.1446
Diabetes	0.1548	-0.3033	-0.0821	0.1970	-0.2850	-0.0141
Echocardiogram	0.2885	-0.4953	-0.1429	nan	-0.5789	-0.0964
Ecoli	-0.0083	-0.4338	-0.2192	-0.2021	-0.4804	-0.1706
Glass	0.2618	-0.4789	-0.1614	0.3871	-0.3030	0.1985
Haberman	-0.1638	-0.3695	nan	-0.1698	-0.3099	nan
Ionosphere	0.1008	-0.5914	-0.4224	0.0329	-0.5747	-0.4235
Iris	0.3303	-0.2257	nan	0.3726	0.0675	nan
Lung Cancer	0.2104	-0.3059	-0.0964	0.5565	-0.4253	-0.1473
Mfeat factors	0.2243	-0.1841	-0.0318	0.2114	-0.2169	-0.0515
Mfeat fourier	-0.0127	-0.3673	-0.2768	-0.0574	-0.3881	-0.2912
Mfeat karhunen	0.1534	-0.3102	-0.1906	0.1706	-0.3862	-0.2794
Mfeat morph	0.1498	-0.0878	0.0096	0.1589	-0.1335	-0.0378
Mfeat pixel	0.2221	-0.2497	-0.1310	0.2891	-0.3084	-0.2032
Mfeat zernike	0.1499	-0.2300	-0.0959	0.1128	-0.2561	-0.1513
mini_newsgroups-m	-0.0300	-0.3482	-0.3623	-0.0993	-0.3616	-0.3848
moviereviews-sorted-m-norm-tf	-0.0317	-0.1321	-0.0865	-0.0074	-0.2129	-0.1528
Optdigits	0.1971	-0.2125	-0.0619	0.1866	-0.2427	-0.0732
Ovarian	0.4730	-0.0081	0.2220	0.5809	0.0742	0.3801
Ozone eighthr	0.2900	-0.1726	-0.0636	0.3000	-0.2433	-0.0652
Ozone onehr	0.2912	-0.1730	-0.0648	0.2980	-0.2441	-0.0663
Page blocks	0.0905	-0.3178	nan	0.1321	-0.3288	-0.1374
Parkinsons	0.3558	-0.0110	0.1965	0.5628	-0.1258	0.1217
Pendigits	0.1975	-0.2750	-0.0869	0.2130	-0.2954	-0.0709
reuters-transcribed	-0.2641	-0.4446	-0.4538	-0.3698	-0.4841	-0.5123
Segment	-0.0381	-0.2321	-0.2481	-0.0880	-0.2353	-0.2062
Sonar	-0.1870	-0.3512	-0.3253	-0.3074	-0.4022	-0.3879
Spectf	0.3904	-0.2215	0.1049	0.5065	-0.3322	0.1218
Spectrometer	0.2063	-0.4595	-0.2103	0.3092	-0.2816	0.0256
Vehicle	0.2976	-0.1099	0.0364	0.4748	-0.0413	0.1808
Vowel	0.0584	0.0098	0.0291	0.1158	0.0689	0.1280
Wdbc	0.3338	-0.3055	0.0023	0.3491	-0.5211	-0.1658
Wdbc	0.3560	-0.3809	0.0351	0.1564	-0.3756	0.1491
Yeast	0.1669	-0.2840	-0.2148	0.1780	-0.3098	-0.1961

Tabela 4.1: Korelacija između LID i *hubness* po algoritmima za LID

Naziv skupa podataka	K=60			K=80		
	LPCA	MLE	TLE	LPCA	MLE	TLE
Wine classified by quality	0.3391	-0.0556	-0.0158	0.3690	-0.0462	-0.0066
Banknote authenticity	0.1422	0.1244	0.0723	0.1580	0.1488	0.1005
Shuttle	0.2291	-0.4397	nan	0.2385	-0.4365	nan
Bar crawl	-0.0371	-0.2712	nan	-0.0452	-0.1671	nan
Iranian telecom customer churn	0.1808	-0.2876	nan	0.1599	-0.2592	nan
Taiwanese bankruptcy prediction	-0.2237	-0.0295	nan	-0.1644	-0.1756	nan
Dexter	nan	-0.1755	-0.1397	-0.1020	-0.1194	-0.0753
Dorothea	-0.1060	-0.4309	-0.4558	-0.2275	-0.4086	-0.4982
Gisette	nan	0.1323	0.2050	0.0162	0.1419	0.2211
Isolet	0.2615	-0.3325	-0.1989	0.2631	-0.3458	-0.2109
Musk	0.1960	-0.2120	-0.1407	0.2288	-0.2306	-0.1588
Abalone	0.2695	-0.3382	-0.0755	0.2676	-0.3198	-0.0743
Arrhythmia	0.2983	-0.5561	-0.1256	0.2314	-0.5735	-0.1722
Diabetes	0.2991	-0.2687	0.0441	0.3511	-0.2930	0.0662
Echocardiogram	nan	-0.7285	-0.3880	nan	-0.7625	-0.3642
Ecoli	-0.2860	-0.4931	-0.1695	-0.3022	-0.4692	-0.1144
Glass	0.5044	-0.3215	0.2202	0.6569	-0.4294	-0.0931
Haberman	nan	-0.3223	nan	nan	-0.2842	nan
Ionosphere	0.0585	-0.5720	-0.4840	-0.0851	-0.6006	-0.5100
Iris	0.3137	0.2539	nan	0.6098	0.2775	nan
Lung Cancer	0.5319	-0.4933	-0.1571	0.4925	-0.5196	-0.1490
Mfeat factors	0.2064	-0.2304	-0.0697	0.2099	-0.2190	-0.0567
Mfeat fourier	-0.0937	-0.3740	-0.2782	-0.1195	-0.3482	-0.2573
Mfeat karhunen	0.1250	-0.4362	-0.3498	0.0648	-0.4832	-0.4152
Mfeat morph	nan	-0.0560	0.0872	nan	-0.1251	-0.0771
Mfeat pixel	0.2790	-0.3691	-0.2882	0.2635	-0.4268	-0.3642
Mfeat zernike	0.1277	-0.2373	-0.1318	0.1452	-0.2189	-0.1084
mini_newsgroups-m	-0.1126	-0.3702	-0.3955	-0.1411	-0.3710	-0.3960
moviereviews-sorted-m-norm-tf	-0.0054	-0.2646	-0.1910	0.0133	-0.3085	-0.2266
Optdigits	0.1646	-0.2726	-0.1026	0.1528	-0.3007	-0.1363
Ovarian	0.5816	0.2174	0.5761	0.5837	0.1859	0.5882
Ozone eighthr	0.3655	-0.2361	-0.0441	0.4536	-0.2434	-0.0319
Ozone onehr	0.3656	-0.2364	-0.0449	0.4516	-0.2445	-0.0329
Page blocks	0.1734	-0.3427	-0.1222	0.1962	-0.3651	-0.1449
Parkinsons	0.5280	-0.3833	-0.2071	0.1701	-0.3968	-0.1463
Pendigits	0.2166	-0.3088	-0.0719	0.2156	-0.3217	-0.0814
Reuters-transcribed	-0.2924	-0.4959	-0.5453	-0.3431	-0.4715	-0.5307
Segment	-0.1557	-0.2535	-0.1897	-0.1512	-0.2759	-0.2206
Sonar	-0.3021	-0.3382	-0.3064	-0.2788	-0.2343	-0.1669
Spectf	0.5589	-0.4292	0.0679	0.5915	-0.4994	0.0352
Spectrometer	0.3979	-0.1212	0.2228	0.5483	-0.0459	0.3507
Vehicle	0.5589	-0.0042	0.2839	0.5828	-0.0018	0.3581
Vowel	0.1523	0.1130	0.2122	0.1680	0.1353	0.2603
Wdbc	0.1761	-0.5325	-0.0887	0.1653	-0.3890	0.1134
Wdbc	0.3157	-0.4646	0.2189	nan	-0.1989	0.4811
Yeast	0.1809	-0.3263	-0.1769	0.1705	-0.3214	-0.1440

Tabela 4.2: Korelacija između LID i *hubness* po algoritmima za LID

Naziv skupa podataka	K=100		
	LPCA	MLE	TLE
Wine classified by quality	0.3794	-0.0362	0.0083
Banknote authenticity	0.2773	0.1157	0.1319
Shuttle	0.2418	-0.4300	nan
Bar crawl	-0.0347	-0.1732	nan
Iranian telecom customer churn	0.1759	-0.2586	nan
Taiwanese bankruptcy prediction	-0.1945	-0.2257	nan
Dexter	-0.0661	-0.0635	-0.0124
Dorothea	-0.1345	-0.4221	-0.5528
Gisette	0.0354	0.1444	0.2281
Isolet	0.2641	-0.3558	-0.2218
Musk	0.2721	-0.2341	-0.1651
Abalone	0.2818	-0.3177	-0.0688
Arrhythmia	0.2004	-0.5705	-0.1699
Diabetes	0.3828	-0.3156	0.0926
Echocardiogram	nan	-0.7523	-0.2849
Ecoli	-0.3748	-0.4298	-0.0922
Glass	0.7621	-0.5340	-0.4168
Haberman	nan	-0.3097	-0.0564
Ionosphere	-0.2196	-0.6125	-0.5335
Iris	0.5242	0.3078	nan
Lung Cancer	0.4481	-0.5597	-0.1440
Mfeat factors	0.2390	-0.1999	-0.0377
Mfeat fourier	-0.1360	-0.3231	-0.2364
Mfeat karhunen	0.0461	-0.5001	-0.4406
Mfeat morph	nan	-0.1119	-0.0877
Mfeat pixel	0.2273	-0.4609	-0.4104
Mfeat zernike	0.1554	-0.1895	-0.0745
mini_newsgroups-m	-0.1491	-0.3689	-0.3931
moviereviews-sorted-m-norm-tf	0.0124	-0.3438	-0.2559
Optdigits	0.1249	-0.3266	-0.1694
Ovarian	0.6310	0.1956	0.6227
Ozone eighthr	0.4901	-0.2580	-0.0244
Ozone onehr	0.4892	-0.2584	-0.0249
Page blocks	0.2033	-0.3918	-0.1659
Parkinsons	-0.2318	-0.2385	0.1351
Pendigits	0.2058	-0.3374	-0.1004
Reuters-transcribed	-0.3081	-0.4464	-0.5277
Segment	-0.0841	-0.2958	-0.2286
Sonar	-0.2022	-0.1572	-0.0568
Spectf	0.6179	-0.5592	0.0134
Spectrometer	0.6687	-0.0711	0.3840
Vehicle	0.5153	0.0047	0.4243
Vowel	0.2254	0.1761	0.3209
Wdbc	0.4484	-0.3164	0.2489
Wdbc	nan	-0.2444	0.4810
Yeast	0.1642	-0.3105	-0.0851

Tabela 4.3: Korelacija između LID i *hubness* po algoritmima za LID

Primene LID i *hubness* u mašinskom učenju

Analiza rezultata korelacije izvedena nad skupovima podataka koja je navedena u poglavlju 4 ukazuje na mogućnost korišćenja kombinacije LID i *hubness*-a u svrhe mašinskog učenja. Dobijena negativna korelacija ukazuje da ova dva parametra sadrže slične informacije ali i na to da se iz njihove kombinacije mogu izvesti i dodatna značenja. Zahvaljujući tome ta kombinacija može pomoći u mašinskom učenju.

U ovom radu ta kombinacija će biti korišćena za poboljšanje kNN klasifikatora. Da bi se uporedila tačnost novog klasifikatora zasnovanog na kombinaciji LID i *hubness*-a, koristiće se kNN klasifikator, *hubness* kNN klasifikator iz rada [1] i LID kNN klasifikator. U ovom poglavlju biće pređene implementacije svih ovih klasifikatora, kao i njihove uporedne performanse. Jedna od mogućih primena biće i pronalaženje *outlier*-a.

Ovo poglavlje će na početku opisati način rada kao i korišćenu implementaciju svakog od gore navedenih klasifikatora. Ovo će podrazumevati detaljan prolaz kroz logiku svakog od klasifikatora, kao i prikaz koda i njegovo objašnjenje za svaki klasifikator.

Potom će se u naslovu 5.5 obraditi način testiranja svakog od klasifikatora kao i kod implementacije koji je korišćen za testiranje. Ovde će biti prikazani i svi rezultati testiranja i izvedeni zaključci.

Poslednji deo ovog poglavlja će ukratko prikazati način pronalaženja *outlier*-a koristeći *hubness* i LID, kako on radi i rezultati njegovog testiranja.

5.1 kNN klasifikator

Korišćen je jednostavan kNN klasifikator. U ovom klasifikatoru korišćena je euklidska razdaljina između čvorova, i po njoj je za svaki čvor odabrano k najbližih suseda. Klasifikator je implementiran u vidu jedne klase. Klasa ima dva metoda to su *fit* i *predict*. Takođe postoji i *_predict* metod koji je namenjen da se poziva iz *predict* metoda.

Pri kreiranju klase prosleđuje se vrednost k koja se čuva u unutrašnjoj globalnoj promenljivoj. Potom se pomoću metode *fit* kojoj se prosleđuju podaci o skupu podataka, koji se čuvaju u dve promenjive. Ponovnim pozivanjem ove funkcije može se promeniti skup podataka nad kojim klasifikator radi.

Metoda *predict* prima niz instanci, i za svaku od njih predviđa vrednost njene klase. Ovaj metod je veoma jednostavan i samo poziva *_predict* metod za svaku instancu u nizu i vraća konačni niz klasa. Metod *_predict* prvo izračunava euklidsku razdaljinu prosleđene instance od svih instanci iz trening skupa, i vadi indekse k najbližih instanci. Iz skupa klasa se vade vrednosti klasa na izvučenim indeksima. Zatim se pronalazi najučestalija vrednost klase u tih k najbližih instanci i to se vraća kao rezultat metoda. U nastavku je kod kNN klasifikator klase:

```
class knn_classifier:
    _name = "knn_classifier"
    def __init__(self, k=3):
        self.k = k

    def fit(self, X_train, y_train):
        self.X_train = X_train
        self.y_train = y_train

    def predict(self, X_test):
        predictions = [self._predict(x) for x in X_test]
        return np.array(predictions)

    def _predict(self, x):
        distances = np.linalg.norm(self.X_train - x, axis=1)

        k_indices = np.argsort(distances)[:self.k]

        k_nearest_labels = [self.y_train[i] for i in k_indices]

        most_common = Counter(k_nearest_labels).most_common(1)
        return most_common[0][0]
```

5.2 Hubness kNN klasifikator

Implementacija ovog klasifikatora je slična kao i kod kNN klasifikatora. U fit metodu ovaj klasifikator takođe prima ne obavezni parametar, istreniran kNN klasifikator koji posle prosleđuje funkciji za izračunavanje težina trening instanci. Vrednost te funkcije se čuva u promenljivoj za težine.

Metod za predviđanje jedne instance ovog klasifikatora pronalazi indekse i klase najbližih k instanci na isti način kao i kNN klasifikator, ali konačnu klasu instance određuje korišćenjem težina instanci. Kada se odrede k najbližih instanci, izvuku se težine za te instance, potom se za svaku klasu sumiraju sve težine. Na kraju se kao vrednost klase prosleđene instance vraća klasa sa najvećom sumom težina.

```
def _predict(self, x):
    distances = np.linalg.norm(self.X_train - x, axis=1)

    k_indices = np.argsort(distances)[:self.k]

    k_nearest_labels = [self.y_train[i] for i in k_indices]
    k_nearest_weights = [self.weights[i] for i in k_indices]

    weighted_votes = Counter()
    for label, weight in zip(k_nearest_labels, k_nearest_weights):
        weighted_votes[label] += weight

    most_common = weighted_votes.most_common(1)
    return most_common[0][0]
```

Težine se računaju na osnovu loše *hubness* vrednosti. Loš *hubness* za neki čvor predstavlja broj čvorova kojima je taj čvor jedan od k najbližih suseda ali pripadaju različitim klasama. Računanje težina se vrši po formulama datim u radu [1]. Prvo se izračuna vrednost lošeg *hubness*-a po sledećoj formuli:

$$h_B(x, k) = \frac{BN_k(x) - \mu_{BN_k}}{\sigma_{BN_k}}$$

Potom se same težine računaju po narednoj formuli:

$$w_k(x) = \exp(-h_B(x, k))$$

Ovo računanje težina je implementirano u metodi *calculate_bad_hubness_weights* koja se poziva iz *fit* metode. Ova metoda prima instance i vrednosti klase svake instance u dva odvojena niza. Takođe prima tri ne obavezna argumenta: već istrenirani kNN klasifikator, broj thread-ova sa kojima može da radi i k . Ako istrenirani klasifikator nije prosleđen, metoda će prvo istrenirati novi. Nakon toga se izvlači graf najbližih suseda iz kNN klasifikatora, i pravi se lista iste dužine kao i broj prosleđenih instanci popunjena nulama. Za svaku granu grafa najbližih suseda proverava se da li su klase oba čvora iste, ako nisu u prethodno napravljenoj listi se vrednost pod indeksom drugog čvora, to je čvor u koji grana ulazi, povećava za jedan. Nakon toga se konačna vrednost računa po formuli koristeći *numpy* metode.

Ovaj klasifikator predstavlja implementaciju *hubness* klasifikatora koji je demonstriran u radu [1]. Dobijeni rezultati za ovaj klasifikator su nešto lošiji nego u radu [1]. Pretpostavljam da je to usled neke greške u ovde korišćenoj implementaciji.

```

def calculate_bad_hubness_weights(
    X, Y, pre_trained_classifier = None,
    n_jobs = 1, n_neighbors = 3
):
    if not pre_trained_classifier:
        knn = KNeighborsClassifier(n_neighbors=n_neighbors, n_jobs=n_jobs)
        knn.fit(X, Y)
    else:
        knn = pre_trained_classifier
    knn_graph = knn.kneighbors_graph()
    graph = nx.from_scipy_sparse_array(knn_graph, create_using=nx.DiGraph)
    bad_hubness = [0] * len(Y)
    for (node, nearest_neighbour) in list(graph.edges):
        if Y[node] != Y[nearest_neighbour]:
            bad_hubness[nearest_neighbour] += 1
    bad_hubness = np.array(bad_hubness)
    mean_bad_hubness = np.mean(bad_hubness)
    bad_hubness_standard_deviation = np.std(bad_hubness)
    mean_subtracted = bad_hubness - mean_bad_hubness
    return np.exp((mean_subtracted / bad_hubness_standard_deviation) * -1)

```

5.3 LID kNN klasifikator

Ovaj klasifikator je sličan onom baziranom na *hubness* ali se zasniva na LID vrednostima. Njegova svrha u ovom radu je da bi se proverilo da li kombinovani klasifikator ima bolje rezultate zahvaljujući kombinovanju vrednosti. Klasa koja implementira ovaj klasifikator je skoro identična onoj koja implementira *hubness* klasifikator jedina razlika je u metodi koja se zove za računanje težina.

Prvo se za svaki čvor x računa LID ocena po sledećoj formuli koja je identična onoj za *hubness*:

$$LID_{ocena}(x, k) = \frac{LID(x) - \mu_{LID}}{\sigma_{LID}}$$

Zatim se težina računa na sličan način ko i ona za *hubness* samo što se ne koristi negativna već sama vrednost ocene, da bi sa vrednošću ocene rasla i težina. Razlog ove izmene je jer u teoriji što je vrednost LID veća to taj čvor nosi više informacija i trebao bi da nosi veću težinu.

$$w_k(x) = \exp(LID_{ocena}(x, k))$$

Implementacija računanja LID težina je veoma prosta. Prvo se izračunaju LID rezultati koristeći *scikit-dimension* implementaciju MLE algoritma sa prosleđenim istreniranim kNN klasifikatorom ili novim koji je kreiran kada nijedan nije prosleđen. Zatim se konačna vrednost računa na osnovu formule.

```

def calculate_lid_weights(X, Y, pre_trained_classifier = None,
    n_jobs = 1, n_neighbors = 3):
    lid = calculate_lid(X, Y, pre_trained_classifier, n_jobs, n_neighbors)
    mean_lid = np.mean(lid)
    lid_standard_deviation = np.std(lid)
    mean_subtracted = lid - mean_lid
    return np.exp((mean_subtracted / lid_standard_deviation) * 1)

```

5.4 LID i *hubness* kNN klasifikator

Kombinacijom težina dobijenih u LID i *hubness* klasifikatorima se dobija ovaj kombinovani klasifikator. Kombinacija težina se vrši prostim sabiranjem težina za LID i *hubness*. Potom se kombinovana težina koristi za određivanje klase tokom glasanja kao i u odvojenim klasifikatorima. Težine se računaju pomoću istih funkcija kao i u odvojenim klasama.

```
class knn_classifier_lid_and_hubness_weight:
    _name = "knn_classifier_lid_and_hubness_weight"
    def __init__(self, k=3):
        self.k = k

    def fit(
        self, X_train, y_train,
        pre_trained_classifier_lid = None,
        pre_trained_classifier_hubness = None
    ):
        self.X_train = X_train
        self.y_train = y_train
        lid_weights = calculate_lid_weights(
            X_train, y_train, n_jobs=12, n_neighbors=100,
            pre_trained_classifier=pre_trained_classifier_lid)
        hubness_weights = calculate_bad_hubness_weights(
            X_train, y_train, n_jobs=12, n_neighbors=self.k,
            pre_trained_classifier=pre_trained_classifier_hubness)
        self.weights = lid_weights + hubness_weights

    def predict(self, X_test):
        predictions = [self._predict(x) for x in X_test]
        return np.array(predictions)

    def _predict(self, x):
        distances = np.linalg.norm(self.X_train - x, axis=1)

        k_indices = np.argsort(distances)[:self.k]

        k_nearest_labels = [self.y_train[i] for i in k_indices]
        k_nearest_weights = [self.weights[i] for i in k_indices]

        weighted_votes = Counter()
        for label, weight in zip(k_nearest_labels, k_nearest_weights):
            weighted_votes[label] += weight

        most_common = weighted_votes.most_common(1)
        return most_common[0][0]
```

5.5 Rezultati poređenja klasifikatora

Svi klasifikatori su ocenjivani stratifikovanom kros-validacijom. Ocenjivanje se vrši u metodi *cross_validate*. Prvo se koristi metod za deljenje skupa podataka na stratifikovane podeoke iz *scikit-learn* biblioteke. Svaki klasifikator se zasebno trenira i ocenjuje nad istim podeocima. Na kraju se vraćaju ocene nad svim podeocima zajedno sa prosekom ocena mapiranim na naziv klasifikatora kojem pripadaju.

```
def cross_validate(X, y, classifiers, n_jobs=1, n_neighbours=3):
    X = np.array(X)
    y = np.array(y)
    kf = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
    knn_hubness = KNeighborsClassifier(n_neighbors=n_neighbours, n_jobs=n_jobs)
    knn_lid = KNeighborsClassifier(n_neighbors=100, n_jobs=n_jobs)


    accuracies = {}
    for classifier in classifiers:
        accuracies.update({classifier._name: []})
    for train_index, test_index in kf.split(X, y):
        x_train, x_test = X[train_index], X[test_index]
        y_train, y_test = y[train_index], y[test_index]

        knn_lid.fit(x_train, y_train)
        knn_hubness.fit(x_train, y_train)


        for classifier in classifiers:
            classifier_accuracies = accuracies.get(classifier._name)
            classifier.fit(
                x_train, y_train,
                pre_trained_classifier_lid=knn_lid,
                pre_trained_classifier_hubness=knn_hubness
            )

            y_pred = classifier.predict(x_test)
            accuracy = accuracy_score(y_test, y_pred)
            classifier_accuracies.append(accuracy)
            accuracies.update({classifier._name: classifier_accuracies})
    for classifier in classifiers:
        mean = np.mean(accuracies.get(classifier._name))
        accuracy = accuracies.get(classifier._name)
        accuracies.update({classifier._name: (mean, accuracy)})
    return accuracies
```

Za ocenjivanje klasifikatora je korišćen deo skupova podataka navedenih u poglavlju 3, i u nastavku će biti navedeni rezultati ovih ocenjivanja. Na slikama 5.1 i 5.2 mogu se videti ocene sva četiri klasifikatora za različite vrednosti k . Kao što se može primetiti kombinovani klasifikator se pokazao bolji od običnog kNN klasifikatora, u nekim skupovima podataka i sa značajnom marginom. U nekim skupovima podataka LID ili *hubness* klasifikatori se mogu pokazati bolji, ali ujedno nad drugim mogu biti mnogo lošiji. Kombinovani klasifikator je u svakom skupu podataka bolji od bar jednog od LID ili *hubness* klasifikatora, ako ne i od oba.




Slika 5.1: Grafikoni ocene svih klasifikatora. Plavo - kNN klasifikator. Žuto - *hubness* kNN klasifikator. Zeleno - LID kNN klasifikator. Crveno - LID i *hubness* kNN klasifikator.




Slika 5.2: Grafikoni ocene svih klasifikatora. Plavo - kNN klasifikator. Žuto - *hubness* kNN klasifikator. Zeleno - LID kNN klasifikator. Crveno - LID i *hubness* kNN klasifikator.

Kao što se može videti na slici 5.3, nad nekim skupovima podataka rezultati nisu bili odlučujući. Nije sasvim očigledno da li se kombinovani klasifikator pokazao bolje od ostalih. Na većini takvih grafova nije najočiglednije koji od klasifikatora je najbolji, jer na nekim imaju skoro identične rezultate. Ovakvi rezultati su zavisniji od samog skupa podataka nego od klasifikatora, ali to su prve naznake da postoji prostor za unapređenje kombinovanog klasifikatora.




Slika 5.3: Grafikoni ocene svih klasifikatora. Plavo - kNN klasifikator. Žuto - *hubness* kNN klasifikator. Zeleno - LID kNN klasifikator. Crveno - LID i *hubness* kNN klasifikator.

Ako u nekom skupu podataka LID ili *hubness* nose mnogo korisnije informacije njihov klasifikator može biti bolji od kombinovanog. U takvim slučajevima kombinovani drži sredinu između ova dva klasifikatora, kao što se može videti na slici 5.4. Kombinovani klasifikator tada nije najbolji ali nije ni daleko od najboljeg. To navodi na zaključak da dok možda nije najbolji klasifikator za sve slučajeve, kombinovani klasifikator u proseku donosi bolje i konzistentnije rezultate od druga dva zasebna klasifikatora.



Slika 5.4: Grafikoni ocene svih klasifikatora. Plavo - kNN klasifikator. Žuto - *hubness* kNN klasifikator. Zeleno - LID kNN klasifikator. Crveno - LID i *hubness* kNN klasifikator.

Postoje i slučajevi gde se kombinovani klasifikator pokazuje lošije od običnog kNN klasifikatora kao što se može videti na slici 5.5. Iako su ovi slučajevi retki oni ipak postoje, i treba imati u vidu da ovaj kombinovani klasifikator neće biti idealan za sve skupove podataka, pogoto za one koji izazivaju probleme pri računanju LID vrednosti.



Slika 5.5: Grafikoni ocene svih klasifikatora. Plavo - kNN klasifikator. Žuto - *hubness* kNN klasifikator. Zeleno - LID kNN klasifikator. Crveno - LID i *hubness* kNN klasifikator.

5.6 Pronalaženje *outlier*-a

Druga moguća primena koja će biti obrđena u ovom radu biće pronalaženje *outlier*-a. Ideja iza ove primene je veoma jednostavna: što je *hubness* vrednost manja a LID vrednost veća za neki čvor, to su veće šanse da je on “usamljeniji” u svom okruženju i veći *outlier*.


Za vrednost LID koristi se isti rezultat koji je dobijen kao težina u LID klasifikatoru. Za *hubness* vrednost se koristi normalizovana *hubness* vrednost nekog čvora, ali izračunata sa 10 puta većim k od onog korišćenog za LID, što je vrednost k koja je već približna broju instanci skupa podataka. Potom se kombinacija računa prostom razlikom između ovih vrednosti, gde se *hubness* množi sa težinom od 0,5. Na kraju se razdaljina do k -tog najbližeg suseda množi sa dobijenim rezultatima. Zbog težine koja se stavlja na *hubness* i činjenice da je *hubness* normalizovan na raspon od 0 do 1, dok LID težina nije, LID će imati mnogo veći uticaj na konačni rezultat.

Prvobitno se koristila normalizovana LID vrednost a ne težina koja je dobijena za LID klasifikator, ali eksperimentalno je pokazano da stavljanjem sve manje težine na *hubness*, rezultat postaje sve bolji. Na kraju su se najbolje pokazale težine LID korišćene za klasifikator.


Za poređenje korišćeni su LOF (*Local Outlier Factor*) i udaljenost od k -tog suseda. Svi skupovi podataka korišćeni za *outlier*-e potiču iz skupova podataka datih u radu [5]. Za poređenje korišćeni su prosečna preciznost, preciznost u prvih n najbolje ocenjenih i površina ispod ROC krive (ROC AUC).

Kao što se može videti na slici 5.6 nad nekim skupovima podataka kombinovani detektor može biti bolji od ostalih, pogotovo pri velikim vrednostima k . Kombinovani detektor može dati dobre rezultate, ali u većini slučajeva pokazuje se lošije od dva kontrolna, kao što se može videti na slici 5.7. Iz tog razloga smatramo da postoji dosta prostora za unapređenje.


Cardiotocography



Glass




HeartDisease




Slika 5.6: Rezultati za *outlier* detekciju. Plavo - LID-hubness detektor, Narandžasto - LOF, Zeleno - udaljenost od k-tog najbližeg suseda. Ako na grafikonu ne postoje sve boje rezultati dva ili više detektora su identični.


Anthyroid



Arrhythmia



Waveform



Slika 5.7: Rezultati za *outlier* detekciju. Plavo - LID-hubness detektor, Narandžasto - LOF, Zeleno - udaljenost od k-tog najbližeg suseda. Ako na grafikonu ne postoje sve boje rezultati dva ili više detektora su identični.

Zaključak

Iz pokazane korelacije i primera klasifikatora možemo zaključiti da LID i *hubness* vrednosti nose različite informacije, koje u kombinaciji mogu biti veoma korisne u nekim aspektima mašinskog učenja.

Kombinacija se pokazala veoma dobro pri klasifikaciji. Ovo se moglo očekivati jer se sam *hubness* pokazao jako dobro u radu [1], dok velika vrednost LID ukazuje na veću količinu jedinstvenih informacija koje nosi neki čvor. Kao što je pokazano kombinovani klasifikator je konzistentno bolji od običnog kNN klasifikatora, ali postoji još prostora za unapređenje.

Kombinovani klasifikator kao i pronalaženje *outlier*-a znatno gubi preciznost pri malim vrednostima k , jer tada LID i *hubness* ne mogu dobro da se računaju. Ovo se vidi već i kod računanja korelacije LID i *hubness* gde se mnogo više grešaka pri proračunima dešavalo za male vrednosti k . Pogotovo svi proračuni vezani za LID znatno opadaju sa smanjenjem k .

Što se tiče pronalaženja *outlier*-a dobijeni rezultati pokazuju da postoji mogućnost da se kombinacija LID i *hubness* koristi u ovu svrhu, ali potrebno je dodatno istraživanje. Rezultati koji su dobijeni daju naznake da se uz dosta izmena može postići neki dobar rezultat, jer se čak i trenutna verzija u dosta slučajeva može porediti sa ostalima. Potrebno je utvrditi razlog zašto je rezultat bolji kada se veći značaj stavi na LID vrednosti.

U teoriji veća vrednost LID bi ukazivala da se taj čvor dosta razlikuje od njegovih najbližih suseda što bi više moglo da ukaže na to da je on *outlier* nego niska *hubness* vrednost. Niska *hubness* vrednost ne mora značiti da je čvor *outlier* već samo da se nalazi na “ivici” nekog uskog skupa čvorova.

Tokom eksperimenata vrednost LID je davala bolje naznake od *hubness*, ali bez *hubness* bi rezultati bili znatno gori. Čak i sa spuštanjem težine *hubness* ispod 0,5 rezultati bi brzo i značajno opadali. Tako da *hubness* ipak daje značajno poboljšanje u pronalaženju *outlier*-a.

Biografija

Rođen 23.05.2000. godine u Sremskoj Mitrovici. Dolazi iz sela Jazak, opština Irig. Otac je doktor veterinarske medicine specijalista, a brat je krenuo njegovim stopama i studira veterinu u Beogradu. Majka vodi računovodstvenu agenciju.

Prva četiri razreda osnovne škole pohađao je u školi "Milica Stojadinović Srпкиnja"ogranak u Jasku dok je naredna četiri nastavio u istoj školi u Vrdniku. Obrazovanje je nastavio u srednjoj školi "Gimnazija Jovan Jovanović Zmaj"u Novom Sadu u odeljenju "Obdareni učenici u računarskoj gimnaziji"(Informatički smer) gde je stekao mnogo praktičnog znanja iz oblasti programiranja. Posle srednje škole se odlučio da upiše Računarske nauke na prirodno matematičkom fakultetu univerziteta u Novom Sadu pošto je želeo da unapredi svoje teorijsko znanje iz računarskih nauka. Po završetku osnovnih studija odmah je upisao master studije za koje piše ovaj master rad.

Kada je upisao master studije počeo je da traži posao u struci. Našao je dve prakse kao softverski inženjer obe su bile u trajanju od po dva meseca kao full stack developer, prva u firmi Synechron, a druga u firmi Noubis. Trenutno je zaposlen u Synechron-u kao inženjer velikih podataka gde radi već godinu dana. Na poslu većinom koristi Scalu i Spark za obradu velike količine podataka.



Literatura

- [1] M. Radovanović, A. Nanopoulos, M. Ivanović (2010). Hubs in space: Popular nearest neighbors in high-dimensional data. *Journal of Machine Learning Research* 11:2487–2531.
- [2] M. E. Houle (2017). Local intrinsic dimensionality I: An extreme-value-theoretic foundation for similarity applications. In *Proceedings of SISAP*, pages 64–79.
- [3] Killian, J.A., Passino, K.M., Nandi, A., Madden, D.R. and Clapp, J., Learning to Detect Heavy Drinking Episodes Using Smartphone Accelerometer Data. In *Proceedings of the 4th International Workshop on Knowledge Discovery in Healthcare Data co-located with the 28th International Joint Conference on Artificial Intelligence (IJCAI 2019)* (pp. 35-42).
- [4] UC Irvine Machine Learning Repository, Pristupljeno: 14.09.2024. Dostupno na: <https://archive.ics.uci.edu/>
- [5] Guilherme O. Campos, Arthur Zimek, Jörg Sander, Ricardo J. G. B. Campello, Barbora Micenková, Erich Schubert, Ira Assent, Michael E. Houle (2015). On the evaluation of unsupervised outlier detection: measures, datasets, and an empirical study
- [6] Jonathan Bac, Evgeny M. Mirkes, Alexander N. Gorban, Ivan Tyukin, Andrei Zinovyev (2021). *Scikit-Dimension: A Python Package for Intrinsic Dimension Estimation*
- [7] Laurent Amsaleg, Oussama Chelly, Michael E. Houle, Ken-ichi Kawarabayashi, Miloš Radovanović, Weeris Treeratanajaru (2019). Intrinsic Dimensionality Estimation within Tight Localities
- [8] Hawkins, D. (1980). *Identification of Outliers*
- [9] Richard E. Bellman (1961). *Adaptive Control Processes: A Guided Tour*. Princeton University Press
- [10] Michael E. Houle (2013). Dimensionality, Discriminability, Density & Distance Distributions
- [11] Jie Chen, Haw ren Fang, and Yousef Saad (2009). Fast approximate kNN graph construction for high dimensional data via recursive Lanczos bisection. *Journal of Machine Learning Research*, 10: 1989–2012
- [12] Elizaveta Levina and Peter J. Bickel (2005). Maximum likelihood estimation of intrinsic dimension. In *Advances in Neural Information Processing Systems* 17
- [13] Taurus T. Dang, Henry Y.T. Ngan, Wei Liu (2015). Distance-Based k-Nearest Neighbors Outlier Detection Method in Large-Scale Traffic Data

- [14] Markus M. Breunig, Hans-Peter Kriegel, Raymond T. Ng, Jörg Sander (2000). LOF: Identifying density-based local outliers
- [15] Mark Fanty, Ronald Cole (1991). Spoken letter recognition

KLJUČNA DOKUMENTACIJSKA INFORMACIJA

UNIVERZITET U NOVOM SADU
PRIRODNO-MATEMATIČKI FAKULTET

Redni broj:	
RBR	
Identifikacioni broj:	
IBR	
Tip dokumentacije:	Monografska dokumentacija
TD	
Tip zapisa:	Tekstualni štampani materijal
TZ	
Vrsta rada:	Master rad
VR	
Autor:	Nikola Radojčić
AU	
Mentor:	dr Miloš Radovanović
MN	
Naslov rada:	Intrinzična dimenzionalnost i njen uticaj na neke aspekte
NR	mašinskog učenja
Jezik publikacije:	srpski (latinica)
JP	
Jezik izvoda:	srpski
JI	
Zemlja publikovanja:	Srbija
ZP	
Uže geografsko područje:	Vojvodina
UGP	
Godina:	2024
GO	
Izdavač:	Autorski reprint
IZ	
Mesto i adresa:	Prirodno-matematički fakultet, Trg Dositeja Obradovića 4,
MA	Novi Sad
Fizički opis rada:	6/41/8/4/6/47
FO	
Naučna oblast:	Veštačka inteligencija
NO	
Naučna disciplina:	Mašinsko učenje
ND	
Predmetna odrednica/ključne reči:	Lokalna intrinzična dimenzionalnost, hubness
PO	
UDK	
Čuva se:	Biblioteka Departmana za matematiku i informatiku, PMF-a
ČU	u Novom Sadu
Važna napomena:	nema
VN	

Izvod:	Ovaj rad analizira korelaciju između intrinzične
IZ	dimenzionalnosti i hubness vrednosti. Pokazuje
	da postoji slabija negativna korelacija. Potom
	koristi ove vrednosti u poboljšanju kNN
	klasifikatora i outlier detekcije.
Datum prihvatanja teme od NN veća:	07.11.2023
DP	
Datum odbrane:	
DO	
Članovi komisije:	
KO	
Predsednik:	dr Miloš Savić, vanredni profesor PMF
Član:	dr Mirjana Mikalački, redovni profesor PMF
Član, mentor:	dr Miloš Radovanović, redovni profesor PMF

KEY WORDS DOCUMENTATION

UNIVERSITY OF NOVI SAD
FACULTY OF SCIENCES

Accession number:	
ANO	
Identification number:	
INO	
Document type:	Monograph publication
DT	
Type of record:	Textual printed material
TR	
Content code:	Master's thesis
CC	
Author:	Nikola Radojčić
AU	
Mentor/comentor:	Miloš Radovanović, Ph. D
MN	
Title:	Intrinsic Dimensionality and its Influence on Some Aspects of Machine Learning
TI	
Language of text:	Serbian (Latin)
LT	
Language of abstract:	English
LA	
Country of publication:	Serbia
CP	
Locality of publication:	Vojvodina
LP	
Publication year:	2024
PY	
Publisher:	Author's reprint
PU	
Publication place:	Faculty of Sciences, Trg Dositeja Obradovića 4,
PP	Novi Sad
Physical description:	6/41/8/4/6/47
PD	
Scientific field:	Artificial intelligence
SF	
Scientific discipline:	Machine learning
SD	
Subject/Key words:	Local intrinsic dimensionality, hubness
SKW	
UC	
Holding data:	Library of Department of Mathematics and Informatics,
HD	Faculty of Sciences in Novi Sad
Note:	None
N	

Abstract:	This paper analyzes the correlation between intrinsic dimensionality and hubness values. It demonstrates that there is a weak negative correlation. Then, it uses these values to improve the kNN classifier and outlier detection.
AB	
Accepted by the Scientific Board:	07.11.2023
ASB	
Defended on:	
DE	
Thesis defend board:	
DB	
President:	Miloš Savić, Ph. D., associate professor
Member:	Mirjana Mikalački, Ph. D., full professor
Member:	Miloš Radovanović, Ph. D., full professor – mentor